8. Neural Network

과목 : 강화학습

담당 교수 : 박태형 교수님

학과 : 지능로봇공학과

학번 : 2023042028

이름 : 권택주

목차

과제 정의

- Neural Network
  - Hyperparameter

과제 풀이

- Neural Network
  - Hyperparameter

과제 결과

과제 정의

Neural Network

- 입력 데이터와 출력 데이터 사이의 비선형 관계를 학습하는 인공신경망 모델
- Hidden Layer와 Node를 통해 입력 데이터의 특징 추출, 예측 결과 생성
- 역전파를 통해 가중치와 편향 갱신, 예측 오차 최소화.

Hyperparameter

- 머신러닝, 딥러닝 모델 학습시키기 전 사용자가 직접 사전에 지정해 주는 설정 값.
- 인공 뉴런이 연결된 링크에 부여된 가중치와 바이어스 값.
- Hidden Layer/Node, Optimizer, Activation Function, Weight Initialization, Learning Rate

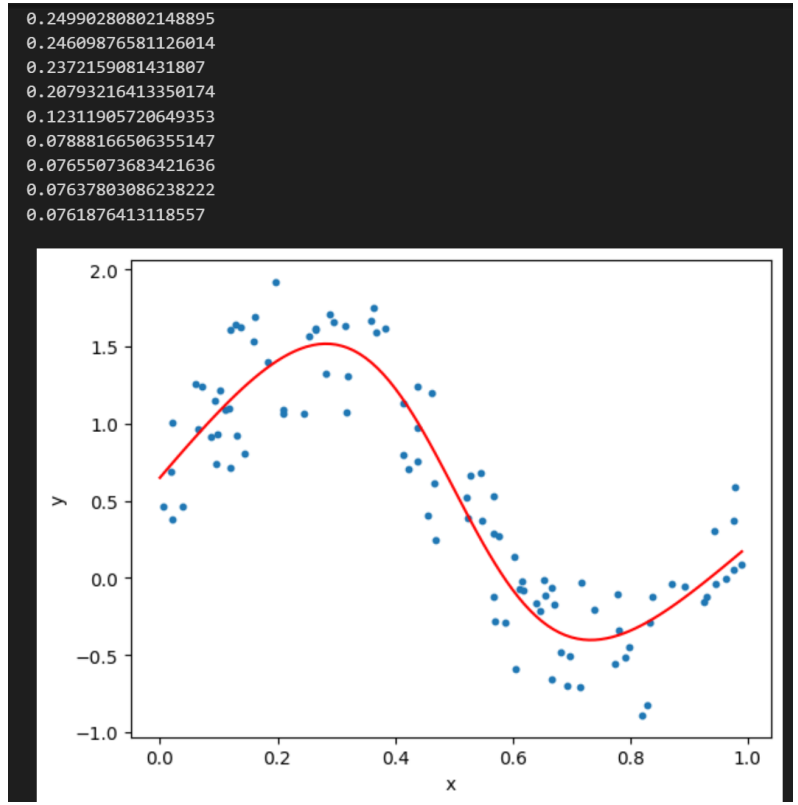
과제 풀이

Basic Code

- 파란 점 : 잡음 포함 Training Data 100개
- 빨간 선 : 학습된 신경망의 예측 결과

그래프 분석

- 목표함수를 이용해 한 주기의 정형파 학습
- 무작위 잡음이 0-1 범위에서 추가, 데이터가 전체적으로 위쪽으로 이동
- 예측 곡선은 잡음이 포함된 데이터의 전체적 정형파 패턴 근사
- 9000회 학습 시 출력 Loss 약 0.0762 기록
- Hidden Layer 1개, Node 10개의 기본 신경망으로 한 주기의 정형파 학습 수행
- 입력 데이터 잡음으로 인해 예측 곡선 – Training Data 사이 오차 발생

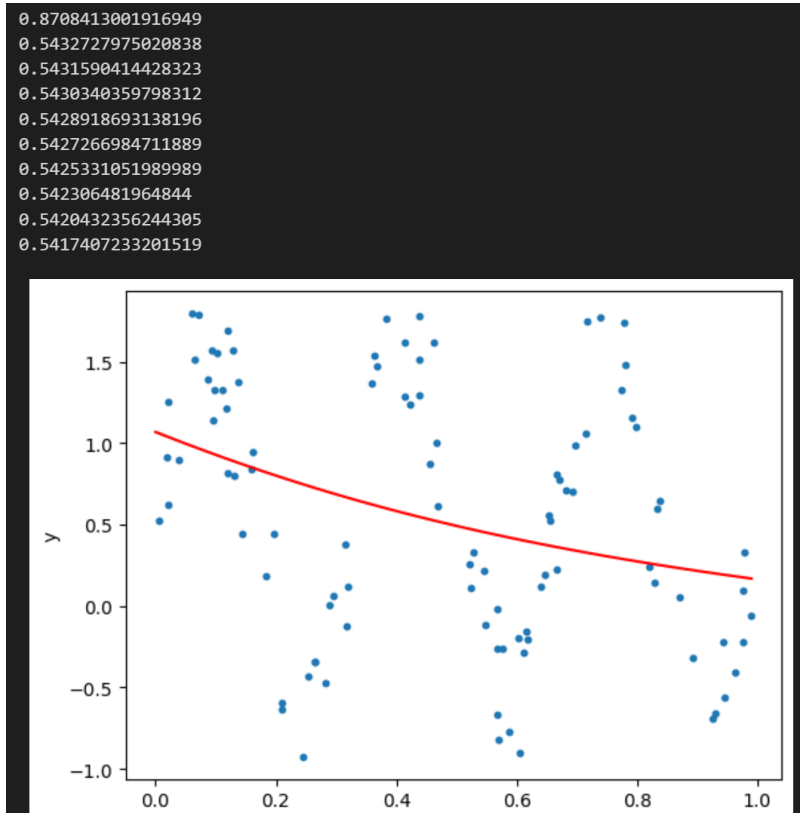


과제 풀이

Basic Code $y = \sin(6\pi x)$

그래프 분석

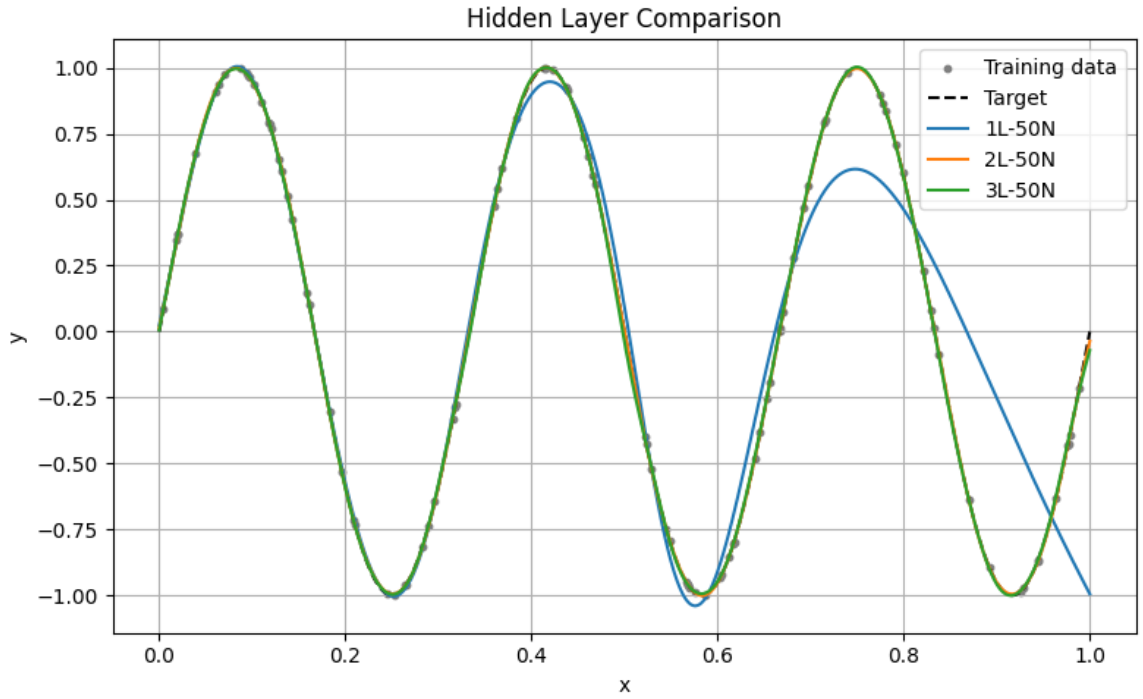
- 목표 함수의 진동횟수 1회 -> 3회 증가
- 기존 신경망 구조, 학습 조건 유지 -> 예측 곡선이 완만하게 감소하는 형태로 형성
- 실제 데이터는 3번 진동, 신경망은 해당 비선형 패턴 충분한 학습 X
- 9000회 학습 시 출력 Loss 0.5417 기록
- 목표 함수의 진동 횟수 증가해 신경망이 학습해야 하는 패턴 복잡도 증가
- 기존 신경망 구조 및 최적화 조건에서 학습이 충분히 진행되지 못한 것으로 판단
- 하이퍼파라미터 변경을 통한 회귀 성능 개선 필요



과제 풀이

1. Hidden Layer 비교

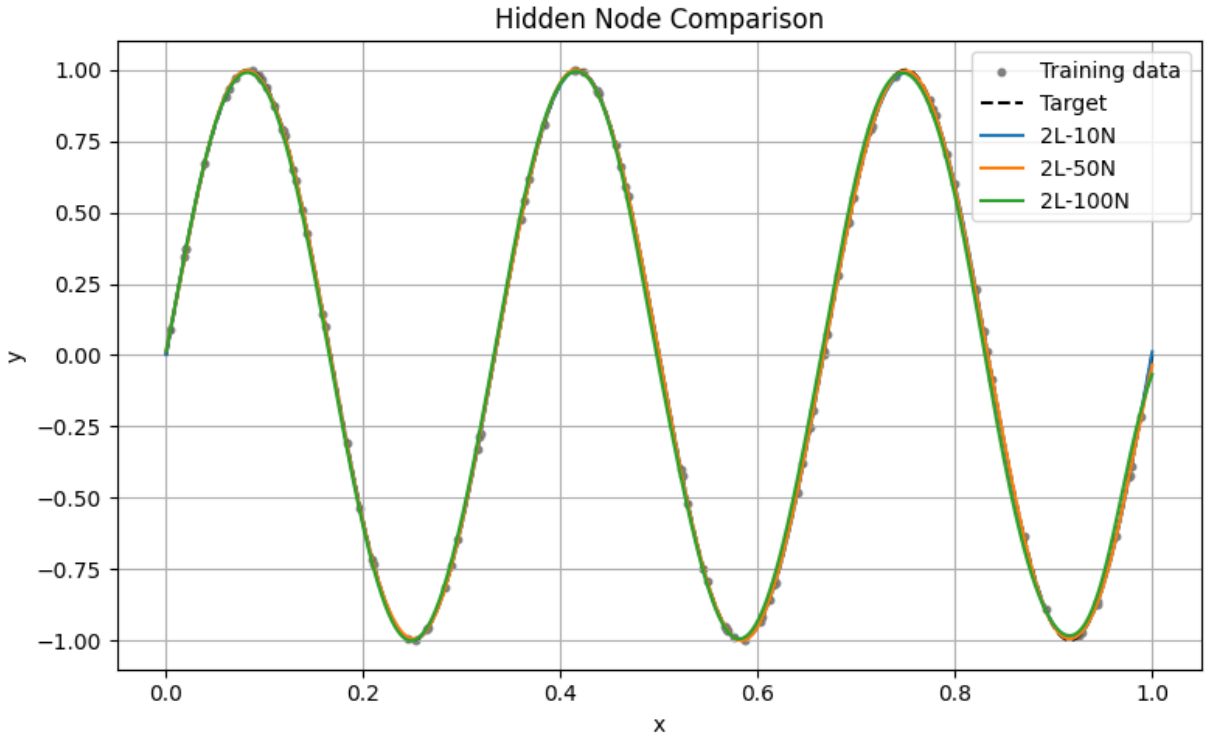
- 1L-50N: 세 번째 정현파 구간에서 목표함수와 큰 오차 발생.
- 2L-50N: 전체 구간에서 목표함수의 주기적 특성을 정확하게 근사.
- 3L-50N: 2L-50N과 유사한 예측 성능을 나타내며 추가적인 성능 향상은 제한적.
- 은닉층을 2개로 구성했을 때 정현파 학습 성능이 크게 개선됨.



과제 풀이

1. Hidden Node 비교

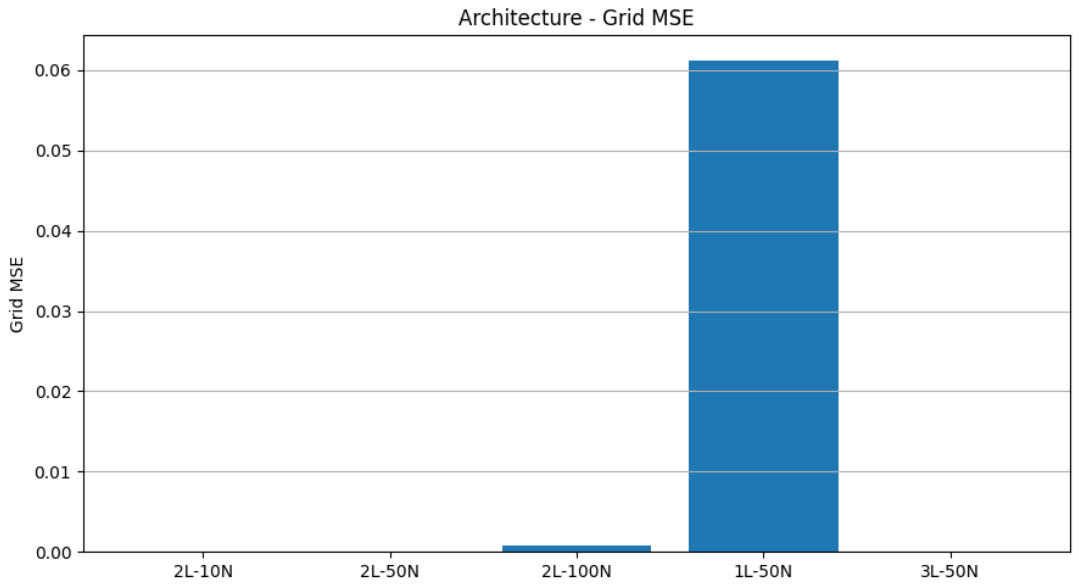
- 2L-10N, 2L-50N, 2L-100N 모두 목표함수에 근접한 예측 결과 도출.
- 노드 수를 100개까지 증가시켜도 예측 정확도가 일관되게 향상되지는 않음.
- 해당 실험에서는 10~50개 노드만으로도 정현파의 주기적 특성을 충분히 학습함.



과제 풀이

1. Hidden Layer / Node MSE

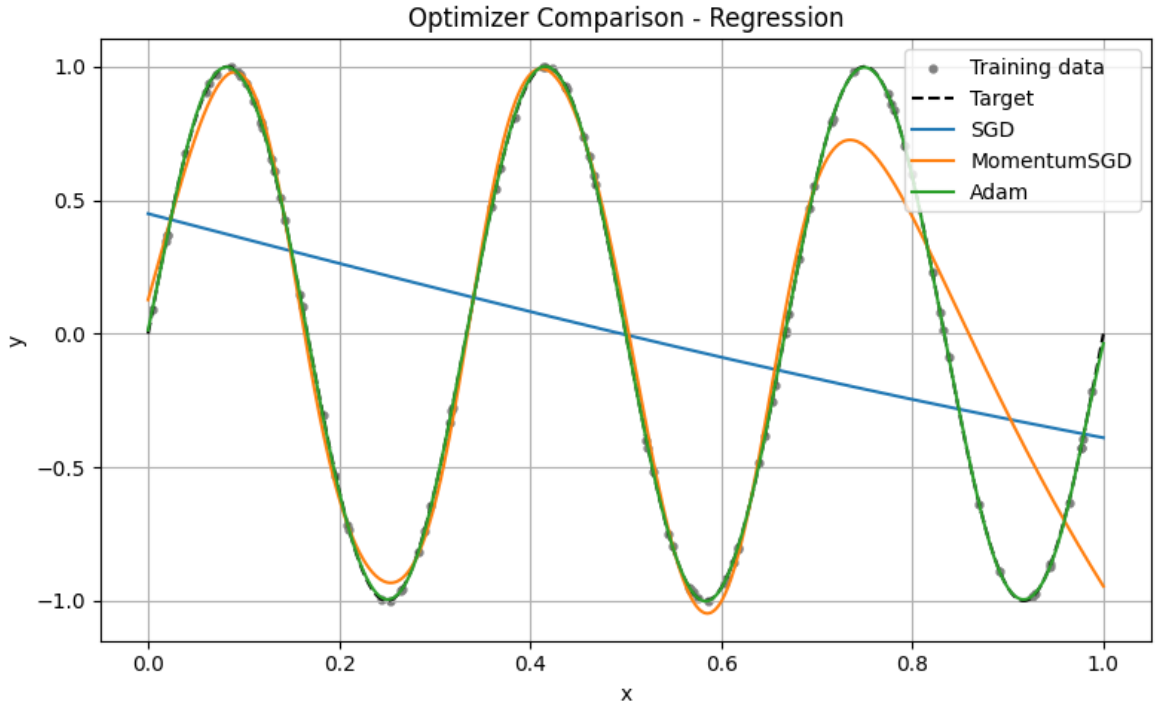
- 1L-50N의 Grid MSE는 약 0.061로 가장 큰 오차 기록.
- 은닉층 2개 및 3개 구성에서는 Grid MSE가 크게 감소.
- 2L-100N은 약 0.0008의 오차를 나타내며, 노드 수 증가에 따른 성능 향상은 확인되지 않음.
- 은닉층의 깊이와 노드 수가 학습 정확도에 영향을 미치며, 적절한 네트워크 구조 선정이 필요함.



과제 풀이

2. Optimizer 회귀 결과 분석

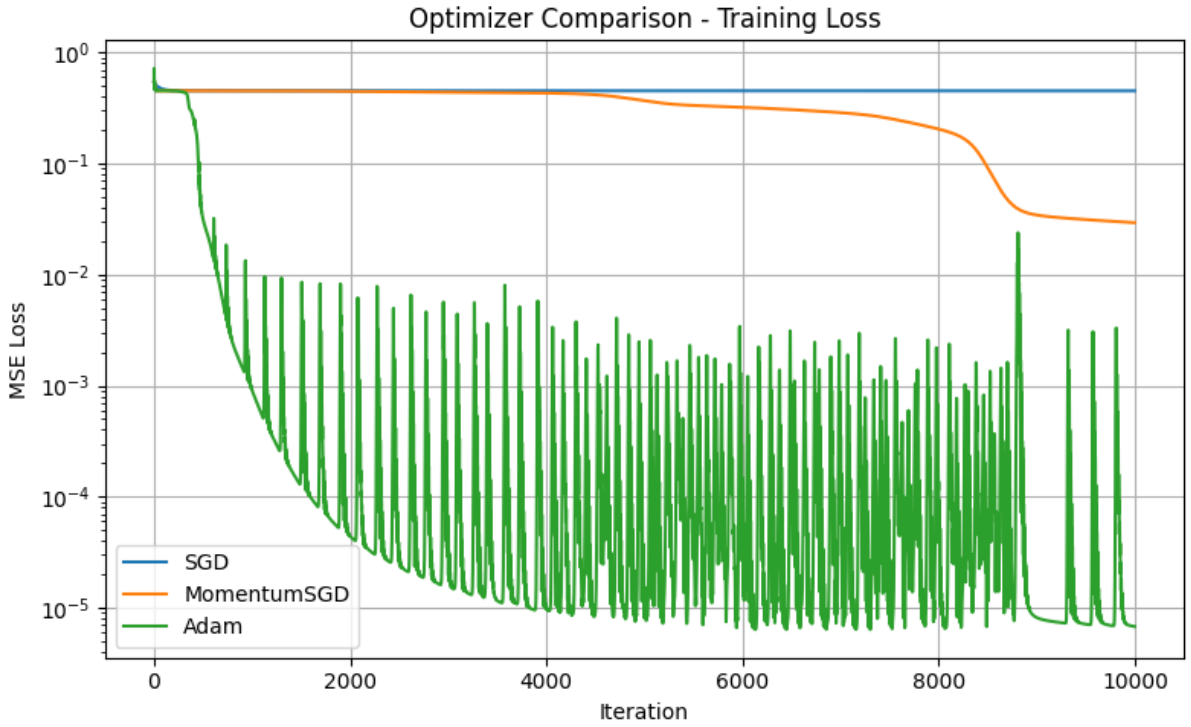
- SGD: 예측 곡선이 직선에 가까워 정현파의 비선형 특성을 학습하지 못함.
- MomentumSGD: 초기 두 주기의 정현파를 근사하지만 마지막 구간에서 오차 발생.
- Adam: 전체 구간에서 목표함수와 거의 일치하는 예측 결과 도출.



과제 풀이

2. Optimizer Training Loss 분석

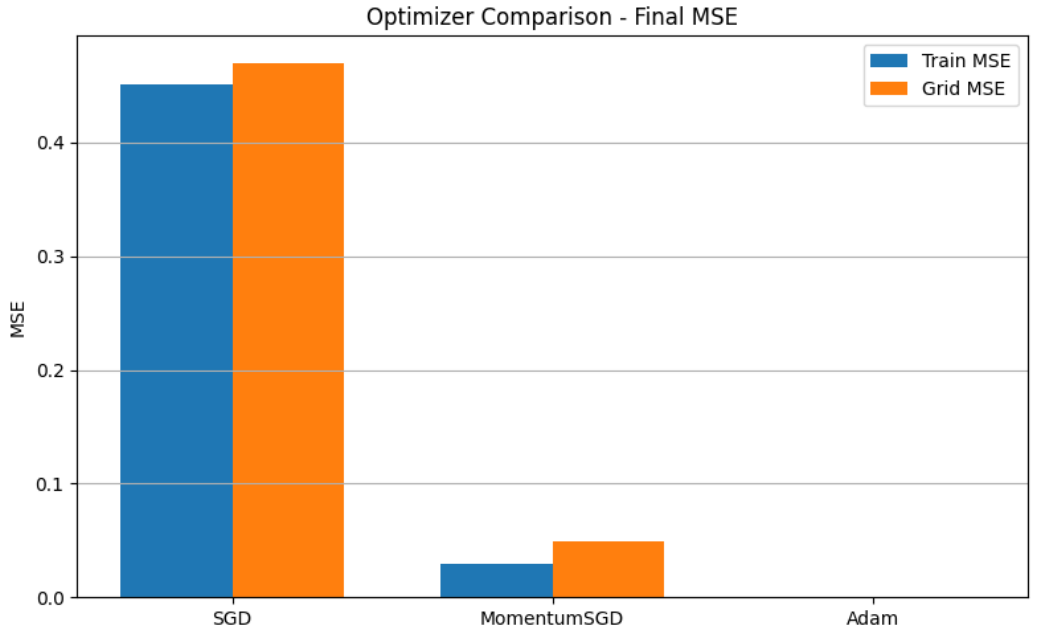
- SGD: 약 0.45 수준에서 Loss가 유지되며 학습 정체 현상 발생.
- MomentumSGD: 학습 후반부부터 Loss가 감소하지만 수렴 속도는 상대적으로 느림.
- Adam: 학습 초기부터 Loss가 급격히 감소하며, 일시적인 진동에도 낮은 오차 수준에 도달함.



과제 풀이

2. Optimizer MSE

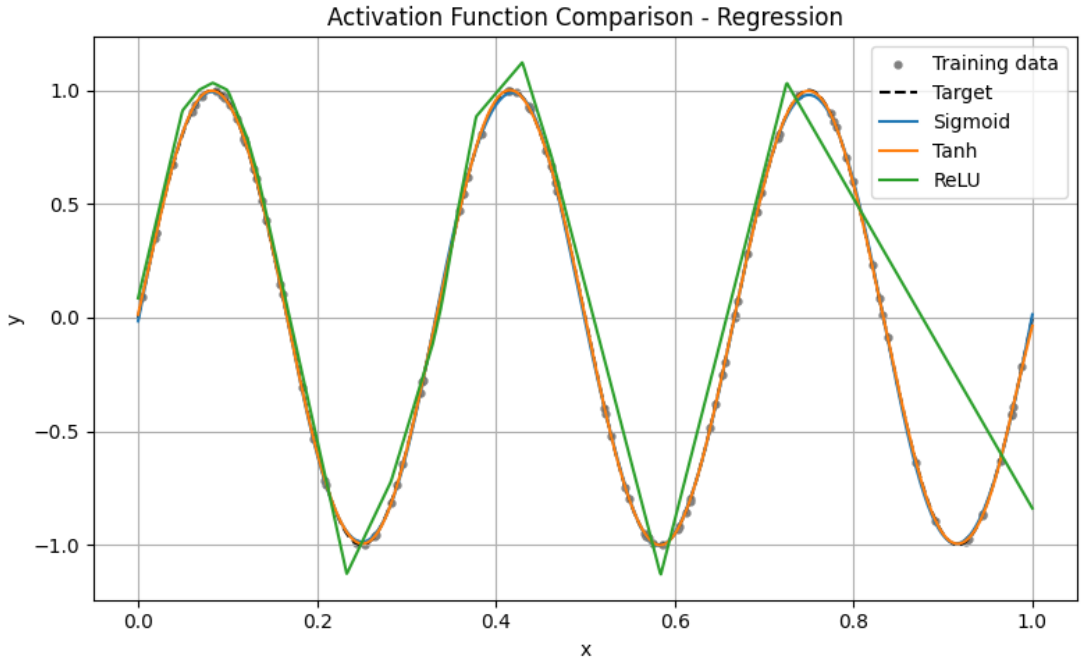
- SGD: Grid MSE 약 0.47로 가장 높은 오차 기록.
- MomentumSGD: Grid MSE 약 0.05로 SGD 대비 학습 정확도 개선.
- Adam: Train MSE와 Grid MSE 모두 매우 낮은 수준 기록.
- 해당 실험에서 Adam이 가장 높은 예측 정확도와 빠른 학습 수렴 특성을 나타냄.



과제 풀이

3. Activation Function 회귀 결과 분석

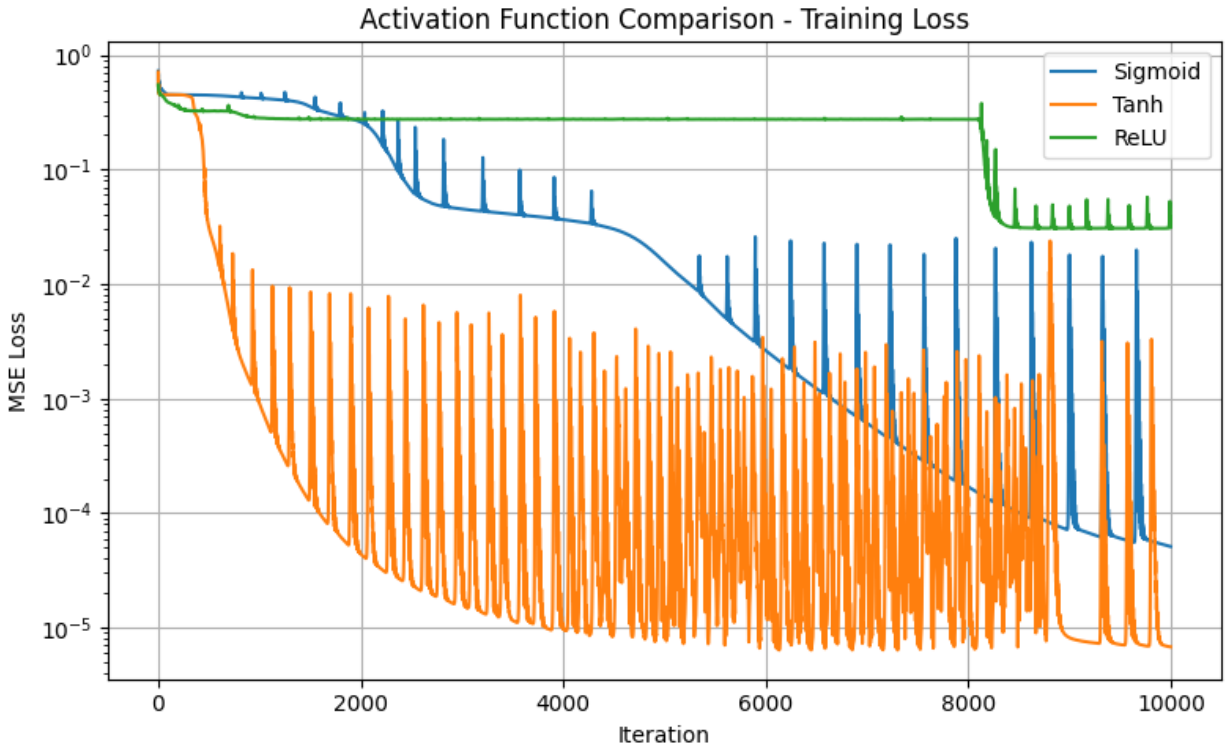
- Sigmoid: 목표함수의 정현파 형태를 전반적으로 정확하게 근사.
- Tanh: 전체 구간에서 목표함수와 높은 일치도를 나타냄.
- ReLU: 일부 구간에서 급격한 기울기 변화와 직선 형태의 오차 발생.
- 활성화 함수의 종류에 따라 비선형 함수의 학습 정확도에 차이가 발생함.



과제 풀이

3. Activation Function Training Loss 분석

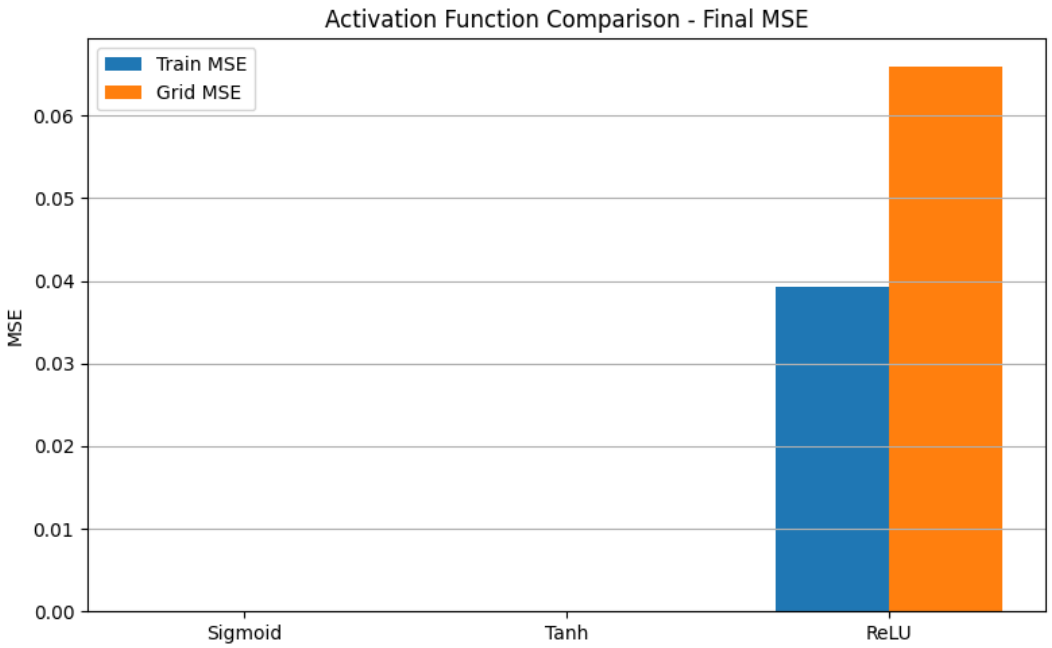
- Sigmoid: 학습 초기 Loss 감소가 느리지만 후반부에는 낮은 수준으로 수렴.
- Tanh: 초기부터 Loss가 빠르게 감소하며 가장 빠른 수렴 특성을 나타냄.
- ReLU: 학습 중반까지 높은 Loss가 유지되며, 후반부에도 상대적으로 큰 오차 발생.



과제 풀이

3. Activation Function MSE

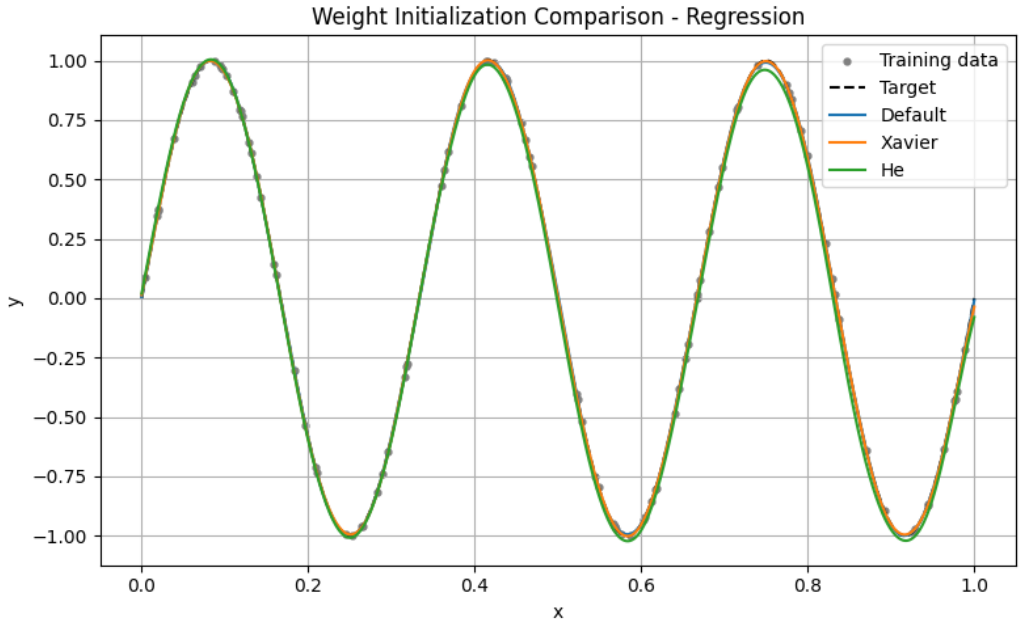
- Sigmoid와 Tanh는 Train MSE 및 Grid MSE 모두 매우 낮은 수준 기록.
- ReLU는 Train MSE 약 0.039, Grid MSE 약 0.066으로 가장 큰 오차 발생.
- Tanh는 빠른 수렴 속도와 높은 정현파 근사 정확도를 나타냄.
- 해당 정현파 회귀 실험에서는 Tanh가 가장 효율적인 학습 결과를 보임.



과제 풀이

4. Weight Initialization 회귀 결과 분석

- Default: 정현파의 주기적 특성을 안정적으로 학습하며 높은 예측 정확도 확보.
- Xavier: 전체 구간에서 목표함수와 높은 일치도를 나타냄.
- He: 정현파의 극댓값과 극솟값 부근에서 상대적으로 큰 편차 발생.
- 가중치 초기화 방식에 따라 최종 예측 결과에 미세한 차이가 발생함.



과제 풀이

4. Weight Initialization Training Loss 분석

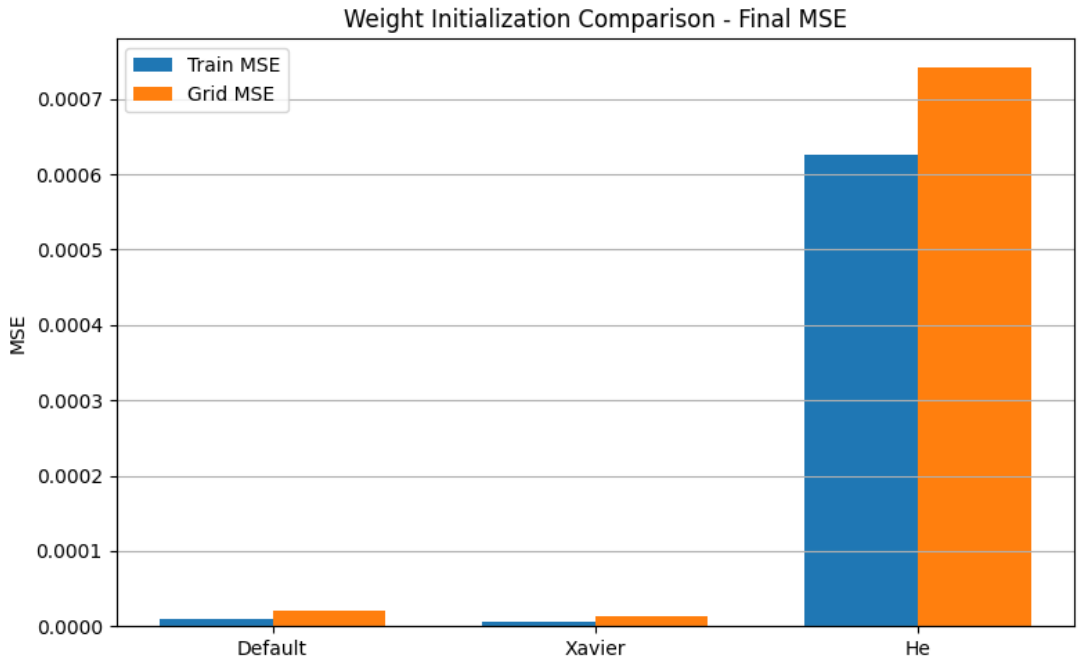
- Default: 학습 초기 Loss가 빠르게 감소.
- Xavier: 점진적으로 Loss가 감소하며 낮은 오차 수준으로 수렴.
- He: 학습 과정에서 상대적으로 큰 Loss 진동이 관찰됨.
- 모든 초기화 방식에서 최종적으로 낮은 학습 오차에 도달함.



과제 풀이

4. Weight Initialization MSE

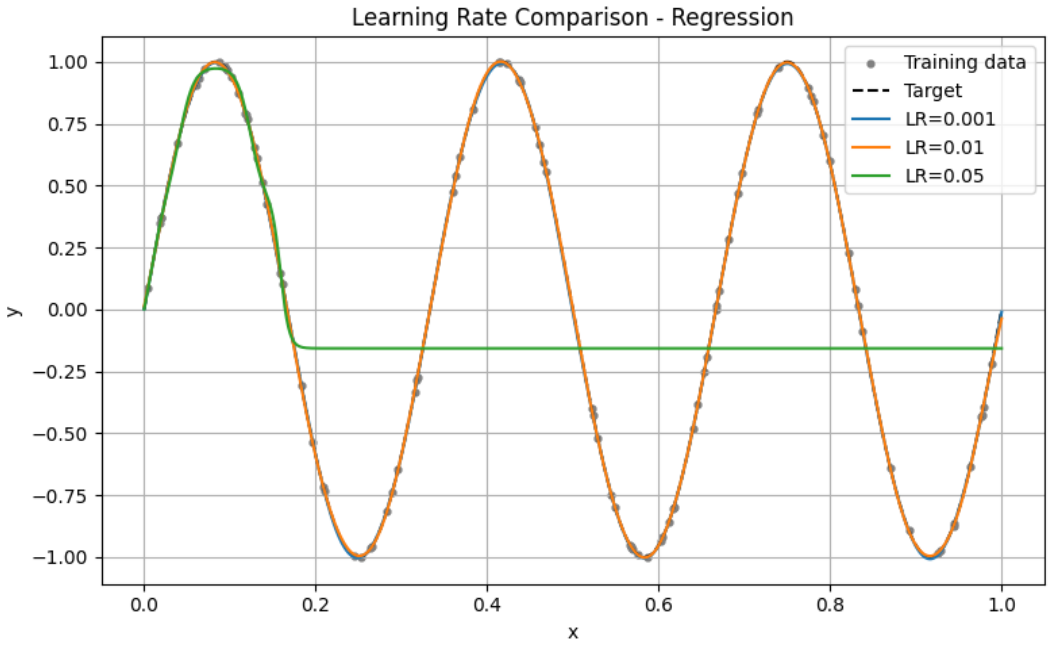
- Xavier: 가장 낮은 Grid MSE를 기록하며 높은 예측 정확도 확보.
- Default: Xavier와 유사하게 낮은 MSE를 기록.
- He: Grid MSE 약 0.00074로 세 가지 초기화 방식 중 가장 높은 오차 기록.
- 해당 실험에서는 Xavier 초기화가 가장 우수한 최종 예측 정확도를 나타냄.



과제 풀이

5. Learning Rate 회귀 결과 분석

- LR=0.001: 목표함수의 전체 정현파 형태를 안정적으로 근사.
- LR=0.01: 목표함수와 높은 일치도를 나타내며 안정적인 예측 결과 도출.
- LR=0.05: 일부 구간 이후 출력값이 일정하게 유지되며 정현파 학습 실패.
- 학습률이 지나치게 증가할 경우 학습 불안정과 예측 성능 저하가 발생함.



과제 풀이

5. Learning Rate Training Loss 분석

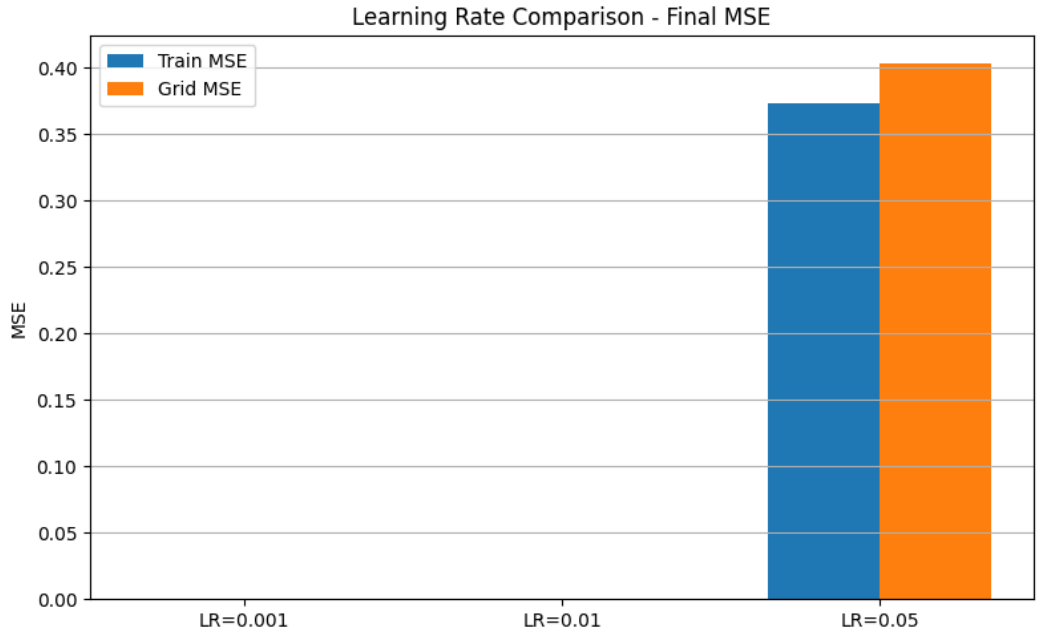
- LR=0.001: Loss가 점진적으로 감소하며 비교적 느린 수렴 특성 발생.
- LR=0.01: 초기부터 Loss가 빠르게 감소하며 낮은 오차 수준으로 수렴.
- LR=0.05: 약 5,800회 반복 이후 Loss가 급격히 증가하고 높은 수준에서 정체됨.
- 해당 실험에서는 LR=0.01이 빠른 수렴 속도와 안정적인 학습 결과를 나타냄.



과제 풀이

5. Learning Rate MSE

- LR=0.001과 LR=0.01은 Train MSE 및 Grid MSE 모두 매우 낮은 수준 기록.
- LR=0.05는 Grid MSE 약 0.40으로 예측 정확도가 크게 감소.
- LR=0.01은 LR=0.001보다 빠른 수렴 특성을 나타내면서 낮은 최종 오차 확보.
- 적절한 Learning Rate 설정이 학습 안정성과 수렴 속도에 중요한 영향을 미침.



과제 결과

1. Hidden Layer / Node

- 은닉층 1개 -> 2개 증가시 정현파의 학습 정확도 크게 개선
- 은닉층 2개 이상에서 추가적인 깊이 증가에 따른 제한적인 성능 향상
- 노드 수 10 – 50개에서도 충분한 학습 성능. 노드 수 증가에 다른 오차 감소는 일관되지 않음

2. Optimizer

- SGD는 학습 정체 현상 발생, 정현파 근사에 실패
- MomentumSGD는 SGD 대비 학습 정확도 개선, 일부 구간에서 오차 발생
- Adam은 가장 빠른 수력 특징과 낮은 최종 MSE 기록

과제 결과

3. Activation Function

- Sigmoid와 Tanh는 정형파의 비선형 특징을 안정적으로 학습
- Tanh는 가장 빠른 Loss 감소와 높은 예측 정확도를 나타냄
- ReLU는 일부 구간에서 큰 오차 발생, 상대적으로 낮은 학습 성능 기록

4. Weight Initialization

- Default와 Xavier는 높은 예측 정확도와 낮은 MSE를 기록
- He는 다른 초기화 방식에 비해 높은 최종 MSE 발생
- 활성화 함수 및 네트워크 구조를 고려한 초기화 방식 선정 필요

과제 결과

5. Learning Rate

- LR = 0.001 : 안정적인 학습이 가능하지만, 상대적을 느린 수렴 속도 발생
- LR = 0.01 : 빠른 수렴 속도와 낮은 최종 MSE를 동시에 확보
- LR = 0.05 : 학습 도중 Loss가 급격히 증가하며 정상적인 정현파 학습 실패
- 본 실험에서는 LR = 0.01이 가장 적절한 학습률로 확인됨

분석

분석

- Hidden Layer / Node: 은닉층 2개 구성에서 높은 정현파 근사 정확도를 확보했으며, 노드 수 증가에 따른 추가적인 성능 향상은 제한적.
- Optimizer: Adam이 가장 빠른 학습 수렴 특성과 높은 예측 정확도를 나타냄.
- Activation Function: Tanh가 빠른 Loss 감소와 안정적인 학습 성능을 기록.
- Weight Initialization: Xavier가 가장 낮은 최종 Grid MSE를 기록.
- Learning Rate: 0.01에서 빠른 수렴과 낮은 예측 오차를 확보.
- 하이퍼파라미터 설정에 따라 학습 수렴 속도와 최종 예측 정확도에 유의미한 차이가 발생함.

고찰

고찰

- 신경망의 깊이와 노드 수를 증가시켜도 학습 정확도가 항상 향상되는 것은 아니며, 목표함수의 복잡도를 고려한 네트워크 설계 필요
- Optimizer와 Learning Rate 설정에 따라 학습 정체 및 불안정 현상이 발생하므로 적절한 최적화 조건 선정이 중요함
- Activation Function과 Weight Initialization의 조합이 학습 안정성과 예측 정확도에 영향을 미칠 수 있음을 확인함.
- 동일한 데이터와 반복 횟수에서도 하이퍼파라미터에 따라 상이한 학습 결과가 도출됨.
- 향후 하이퍼파라미터의 조합별 실험과 반복 학습을 통해 성능의 일관성 및 일반화 능력을 추가적으로 검증할 필요가 있음.